

# 习题一

141220120, 徐世坚

2017 年 3 月 15 日

## Problem 1

若数据包含噪声，则假设空间中有可能不存在与所有训练样本都一致的假设，此时的版本空间是什么？在此情形下，试设计一种归纳偏好用于假设选择。

**Solution.** 此时的版本空间可以定义为：能够正确判断样本最多的假设，或者是设定一个阈值，判断正确达到阈值及以上的假设。

此时的归纳偏好可以定为：在一定正确率的前提下，采用奥卡姆剃刀原则，选择最简单的假设。

## Problem 2

对于有限样例，请证明

$$\text{AUC} = \frac{1}{m^+m^-} \sum_{x^+ \in D^+} \sum_{x^- \in D^-} \left( \mathbb{I}(f(x^+) > f(x^-)) + \frac{1}{2} \mathbb{I}(f(x^+) = f(x^-)) \right)$$

**Proof.**  $\text{AUC} = \frac{1}{2} \sum_i^{m-1} (x_{i+1} - x_i)(y_{i+1} + y_i)$   
 $= \frac{1}{2} \sum_{(x_i, y_i) \in D^-} \frac{1}{m^-} (2y_i)$   
 $= \frac{1}{m^-} \sum_{(x_i, y_i) \in D^-} y_i$   
 $= \frac{1}{m^-} \sum_{(x_i, y_i) \in D^-} \frac{k}{m^+}$   
 $= \frac{1}{m^-m^+} \sum_{x^- \in D^-} (\text{当前样本之前的真正例个数})$

将样例按预测值从大到小排序，因为当前的样本是个反例，所以该样本之前的真正例的个数等于预测值比它大的正例的个数，对应于 $\mathbb{I}(f(x^+) > f(x^-))$ ，当因为可能存在正例的预测值和当前的反例预测值相等，那么在排序中可能排在前也可能排在后，取平均就对应于 $\frac{1}{2} \mathbb{I}(f(x^+) = f(x^-))$

$\therefore \text{上式} = \frac{1}{m^-m^+} \sum_{x^- \in D^-} \sum_{x^+ \in D^+} (\mathbb{I}(f(x^+) > f(x^-)) + \frac{1}{2} \mathbb{I}(f(x^+) = f(x^-)))$  □

## Problem 3

在某个西瓜分类任务的验证集中，共有10个示例，其中有3个类别标记为“1”，表示该示例是好瓜；有7个类别标记为“0”，表示该示例不是好瓜。由于学习方法能力有限，我们只能产生在验证集上精度(accuracy)为0.8的分类器。

(a) 如果想要在验证集上得到最佳查准率(precision)，该分类器应该作出何种预测？

此时的查全率(recall)和F1分别是多少？

(b) 如果想要在验证集上得到最佳查全率(recall)，该分类器应该作出何种预测？

此时的查准率(precision)和F1分别是多少？

**Solution.**  $\because$  accuracy=0.8

$\therefore$  有8个样本分类正确

设  $TP = x, x \in 0, 1, 2, 3$ ; 设  $TN = 8 - x, FN = 3 - x, FP = 7 - (8 - x) = x - 1$ .

$$P = \frac{TP}{TP+FP} = \frac{x}{2x-1}, R = \frac{TP}{TP+FN} = \frac{x}{3}.$$

(a) 当  $x=1$ , 查准率最高,  $P=1$

$TP=1, FN=2, TP=0, TN=7$

$$R = \frac{1}{3}$$

$$F1 = \frac{2 \times P \times R}{P+R} = 0.5$$

(b) 当  $x=3$ , 查全率最高,  $R=1$

$TP=3, FN=0, FP=2, TN=5$

$$P = \frac{3}{5}$$

$$F1 = \frac{2 \times P \times R}{P+R} = 0.75$$

## Problem 4

在数据集  $D_1, D_2, D_3, D_4, D_5$  运行了  $A, B, C, D, E$  五种算法，算法比较序值表如表1所示:

表 1: 算法比较序值表

数据集	算法A	算法B	算法C	算法D	算法E
$D_1$	2	3	1	5	4
$D_2$	5	4	2	3	1
$D_3$	4	5	1	2	3
$D_4$	2	3	1	5	4
$D_5$	3	4	1	5	2
平均序值	3.2	3.8	1.2	4	2.8

使用Friedman检验( $\alpha = 0.05$ )判断这些算法是否性能都相同。若不相同，进行Nemenyi后续检验( $\alpha = 0.05$ )，并说明性能最好的算法与哪些算法有显著差别。

**Solution.** Friedman检验:  $\tau_{\chi^2} = \frac{248}{25}$ ,  $\tau_F = 3.937$ . 它大于  $\alpha = 0.05$  时的F检验临界值3.007，因此拒绝所有算法性能相同这个假设。

Nemenyi检验:  $CD = 2.728$ , 算法C最好，它与算法D的差距超过临界值域，所以，最好的算法C和算法D有显著差别。